

$$\text{bytes_moved}(S, B) = 4(1040324 + B(91S^2 + 2148))$$

$$\text{Flops}(S, B) = B(17730S^2 + 313600)$$

$$\text{Memory}(S, B) = 4(1040324 + B(26S^2 + 868))$$

$$\text{Latency}(S, B, \theta) = \max\left(\frac{\text{Flops}(S, B)}{\theta_c}, \frac{\text{bytes_moved}(S, B)}{\theta_m}\right)$$

$$\text{Energy}(S, B, \theta) = \theta_p \text{Latency}(S, B, \theta)$$

Рассчитываем формулы:

Заметим, что $S_{out} = \frac{S_{in} + 2p - k}{z} + 1$ при заданных условиях k - нечетное и $p = k/2$, упрощается до $\frac{S_{in}}{z} + 1$ с округлением до целого вверх. Также, из условия все S_{in} - кратны 16, поэтому детали с округлением можно отбросить: $S_{out} = \frac{S_{in}}{z}$

1 Conv1: $32 \cdot S_{out}^2 \cdot 293 = 937 \cdot \left(\frac{S_{in}}{z}\right)^2 = 2344 \cdot S_{in}^2$

2 Relu1: $32 \cdot S_{in}^2 / 4 = 8 S_{in}^2$

3 MP : $256 (S_{out}^2) / 4^2 = 16 S_{in}^2$

4 Conv2: $102336 \cdot S_{out}^2 = 6396 \cdot S_{in}^2$

5 Relu2: $64 \cdot S_{in}^2 / 4^2 = 4 S_{in}^2$

6 Conv3: $147328 \cdot S_{out}^2 = 2302 \cdot S_{in}^2$

7 Relu3: $128 \cdot (S_{in})^2 / 8^2 = 2 S_{in}^2$

8 Conv4: $652160 \cdot S_{out}^2 = 1020 S_{in}^2$

9 Relu4: $256 \cdot S_{in}^2 / 8^2 = 4 S_{in}^2$

10 Conv5: $1173382 \cdot S_{out}^2 = 4607 S_{in}^2$

11 Relu5: $256 \cdot S_{in}^2 / 16^2 = S_{in}^2$

12 Conv6: $261632 \cdot S_{out}^2 = 1022 S_{in}^2$

13 Relu6: $512 \cdot S_{in}^2 / 16^2 = 2 S_{in}^2$

14 AAR : $512 \cdot S_{in}^2 / 16^2 = 2 S_{in}^2$

15 Flatten: 0

16 Linear: 262144

17 Relu: 256

18 Linear: 51200

Итого: $17730 S_{in}^2 + 313600$

Расчет Memory

У сверток конволюционной выходной канал имеет размер
размером $C_m \times K \times K \Rightarrow P_{conv} = Count_{C_m} K^2$, bias описываем

Для Linear $P_{linear} = m \cdot n + m$

Relu и Flatten не занимают место.

Тогда всего параметров: 1040324

Морель равна в float32 $\Rightarrow 1040324 \cdot 4 = 4161296 \text{ float}$

Всего морель всего 4161296 float

Посчитаем все активации:

$$\text{Вход: } 3 \cdot S_m^2$$

$$\text{Conv1: } 32 \cdot S_m^2 / 4 = 8 S_m^2$$

$$\text{MP: } 32 \cdot S_m^2 / 16 = 2 S_m^2$$

$$\text{Conv2: } 64 \cdot S_m^2 / 16 = 4 S_m^2$$

$$\text{Conv3: } 128 \cdot S_m^2 / 64 = 2 S_m^2$$

$$\text{Conv4: } 256 \cdot S_m^2 / 64 = 4 S_m^2$$

$$\text{Conv5: } 256 \cdot S_m^2 / 256 = S_m^2$$

$$\text{Conv6: } 512 \cdot S_m^2 / 256 = 2 S_m^2$$

$$\text{AAP: } 512$$

$$\text{Linear: } 256$$

$$\text{Linear: } 100$$

Активации занимают $26 S_m^2 + 868$

$$\text{Итого в памяти (S, B) = } 4(1040324 + B(26 \cdot S^2 + 868))$$

Расчет latency

На выполнение требуется время $T_c = \frac{Flops(S, B)}{\theta_c}$

Время необходимое на передачу данных $T_m = \frac{Q(S, B)}{\theta_m}$

где: Q - объем прочитанных и записанных байт

Предположим, что вычисления и передача данных перекрываются, тогда:

$$Latency(S, B, \theta) = \max\left(\frac{Flops(S, B)}{\theta_c}, \frac{Q(S, B)}{\theta_m}\right)$$

При допущении однократных чтений и записи:

$$Q(S, B) = 4(1040324 + B(9/576 + 2/48))$$

Итого:

$$Latency(S, B, \theta) = \max\left(\frac{B(17730 s^{-2} + 313600)}{\theta_c}, \frac{4(1040324 + B(9/576 + 2/48))}{\theta_m}\right)$$

Расчет энергии:

Приблизительно считаем среднюю мощность постоянной $E \approx P \cdot T$

$$\text{Тогда } Energy(S, B, \theta) = P_r \cdot Latency(S, B, \theta)$$

где P_r - средняя мощность в ваттах.